Bedingte Verteilung & Erwartung

$P_B(A) = P(A|B) = \frac{P(A\cap B)}{P(B)} = \frac{1}{P(B)}\cdot\int \mathbb{1}_{A\cap B}\,dP = \underbrace{\frac{1}{P(B)}\int_A \mathbb{1}_B\,dP}_{\text{P-Dichte von } P_B}$

0.1) $E(X|B) = E_{P_B}(X) = \int_\Omega X\,dP_B = \frac{1}{P(B)}\cdot\int_B X\,dP = \frac{1}{P(B)}\cdot E_P(\mathbb{1}_B\cdot X)$

Diskret verteilte ZV Y ($Y(\Omega)=\{y_i,\ i\in I\subseteq\mathbb{N}\}$)

Berechnung: $E(X|Y=y_i) = \frac{1}{P(Y=y_i)}\cdot\int_{\{Y=y_i\}} X\,dP$

$E(X|Y) = \sum_{i\in I} E(X|Y=y_i)\cdot\mathbb{1}_{\{y_i\}}(Y)$

=> ist eine von Y abhängige ZV

=> $E(X|Y) =: g(Y)$

mit $g:\mathbb{R}\to\mathbb{R}$, $g(y) = \begin{cases} E(X|Y=y), & \text{falls } P(Y=y)>0 \\ 0, & \text{sonst}\end{cases}$

0.4) $\int_{Y^{-1}(B)} E(X|Y)\,dP = \int_{Y^{-1}(B)} X\,dP$

↳Bew: $\forall i: \int_{Y^{-1}(y_i)} E(X|Y)\,dP = \int_\Omega \mathbb{1}_{\{y_i\}}(Y)\cdot\sum_{j\in I}\left(E(X|Y=y_j)\cdot\mathbb{1}_{\{y_j\}}(Y)\right)dP$

$= \int_\Omega \mathbb{1}_{\{y_i\}}(Y)\cdot E(X|Y=y_i)\,dP = E(X|Y=y_i)\cdot\int_\Omega \mathbb{1}_{\{y_i\}}(Y)\,dP$

$= \underbrace{E(X|Y=y_i)}_{=\frac{1}{P(Y=y_i)}\cdot\int_{\{Y=y_i\}} X\,dP}\cdot P(Y=y_i) = \int_{\{Y=y_i\}} X\,dP = \int_{Y^{-1}(B)} X\,dP$

• $E(X|X)(\omega) = E(X|X=x_i) = \frac{1}{P(X=x_i)}\cdot\int_{\{X=x_i\}} X\,dP = \frac{1}{P(X=x_i)}\cdot P(X=x_i)\cdot x_i$

=> $E(X|X)=X$ P-f.s.

stetige ZV Y wenn X,Y gemeinsame Vert. mit λ^2-Dichte f:

Berechnung: $E(X|Y=y) = \int_{\mathbb{R}} x\cdot f(x|y)\,dx$

=> mit $f_Y(y) = \int f(x,y)\,dx$ ist Randdichte P^Y

=> $P(X\in A|Y=y) := \int_A \frac{f(x,y)}{f_Y(y)}\,dx$ => $P(X\in A|Y)$ ↘ beides sind ZVen

$E(X|Y=y) := \int_{\mathbb{R}} x\cdot\frac{f(x,y)}{f_Y(y)}\,dx$ => $E(X|Y)$ ↗

$f(x|y) = \frac{f(x,y)}{f_Y(y)}$ falls $f_Y(y)>0$, sonst 0

0.6) $\int_{Y^{-1}(B)} E(X|Y)\,dP = \int_{Y^{-1}(B)} X\,dP$ quasi $E(E(X|Y\in B)) = E(X|Y\in B)$

Bsp. 0.7) Sei: $f(x|y) = \frac{1}{\sqrt{2\pi}}\cdot e^{-\frac{(x-y)^2}{2}}$, $x\in\mathbb{R}$ $\sim N(y,1)$

=> $E(X|Y)=Y$: $E(X|Y=y) = \int x\cdot f(x|y)\,dx \overset{EW(N(y,1))}{=} y$

Bedingte Erwartung

0.8) Faktorisierungslemma

$$\begin{tikzcd} (\Omega,\sigma(Y)) \arrow[r, "Y"] \arrow[dr, "X"'] & (\mathbb{R}^k,\mathcal{B}^k) \arrow[d, "g"] \\ & (\mathbb{R},\mathcal{B}) \end{tikzcd}$$

↳X ist $\sigma(Y)$-$\mathcal{B}$-messbar, wenn es ein g gibt mit $X = g\circ Y$

=> gibt genau ein messbares X

=> bedingte Erwartung: $E(X|Y)$

Eigenschaften

i) Linearität: $E(\alpha X_1+\beta X_2|Y) = \alpha\cdot E(X_1|Y) + \beta\cdot E(X_2|Y)$

ii) Monotonie: $X_1\le X_2$ => $E(X_1|Y)\le E(X_2|Y)$

iii) X_1, X_2 integrierbar: X_1 Y-messbar => $E(X_1\cdot X_2|Y) = X_1\cdot E(X_2|Y)$

=> $E(X_1|Y) = X_1\cdot E(1|Y) = X_1$

iv) X, Y st. unabh. => $E(X|Y)=E(X)$

v) Y konstant => $E(X|Y)=E(X)$ Bew: diskretes Y

vi) Formel der iterierten Erwartung: $E(E(X|Y))=E(X)$

↳Bew: $E(E(X|Y)) = \int_\Omega E(X|Y)\,dP = \int_{Y^{-1}(\mathbb{R})} E(X|Y)\,dP = \int_{Y^{-1}(\mathbb{R})} X\,dP$

! => Beweise: nicht direkt sondern mit: $\int_{Y^{-1}(B)} E(X|Y)\,dP = \int_{Y^{-1}(B)} X\,dP$

↳dann Argumente betrachten

bedingte Varianz & Kovarianz ($X,Y\in\mathcal{L}_2(P)$; Z Zufallsvektor)

$Var(X|Z) := E([X-E(X|Z)]^2|Z)$

$Cov(X,Y|Z) := E([X-E(X|Z)]\cdot[Y-E(Y|Z)]|Z)$

$= \dots =$ (Tip: $E(E(X|Z)|Z)$ rausziehen: $E(X|Z)\cdot E(1|Z)$)

$= E(X\cdot Y|Z) - E(X|Z)\cdot E(Y|Z)$

! $Cov(X,Y) = E(Cov(X,Y|Z)) + Cov(E(X|Z), E(Y|Z))$

↳denn $Cov(X,Y) = E(X\cdot Y) - E(X)\cdot E(Y)$

! $Var(X) = E(Var(X|Z)) + Var(E(X|Z))$

=> $Var(X)\ge E(Var(X|Z))$

• X,Z st. unabh. => $Var(E(X|Z)) = Var(\overbrace{E(X)}^{\text{keine ZV}}) = 0$

Tip: $Var(E(X|Z)) = E([E(S|G)]^2) - [E(E(S|G))]^2$

Darstellung ($X\in\mathcal{L}_1$ oder $X\in\mathcal{L}_0^+$; Y Zufallsvektor)

0.17) ∃ messbare Fkt g mit $E(X|Y) = g(Y)$ P.-f.s.

0.18)? ↳Beweis: „trivial mit 0.8)"

↳g ist P-f.s. eindeutig und $\int_{Y^{-1}(B)} X\,dP = \int_B g\,dP^Y$

Bsp 0.22) $f(x,y) = \begin{cases} 6xy(2-x-y), & x,y\in(0,1) \\ 0, & \text{sonst}\end{cases}$

=> $E(X|Y)$ bestimmen

i) Randdichte von Y berechnen

$f_Y(y) = \int_{\mathbb{R}} 6xy(2-x-y)\cdot\mathbb{1}_{(0,1)}(x)\cdot\mathbb{1}_{(0,1)}(y)\,dx$

$= \mathbb{1}_{(0,1)}(y)\cdot\int_0^1 12xy - 6x^2y - 6xy^2\,dx$

$= \dots = \mathbb{1}_{(0,1)}(y)\cdot(4y-3y^2)$

ii) $E(X|Y=y) = \int_{\mathbb{R}} x\cdot\frac{f(x,y)}{f_Y(y)}\,dx = \int_0^1 \mathbb{1}_{(0,1)}(y)\cdot x\cdot\frac{6x(2-x-y)}{4-3y}\,dx$

$= \dots = \mathbb{1}_{(0,1)}(y)\cdot\frac{2{,}5-2y}{4-3y}$

iii) $E(X|Y) = \mathbb{1}_{(0,1)}(Y)\cdot\frac{2{,}5-2Y}{4-3Y}$

=> evtl. zwischen i) und ii) erstmal $f(x|y) = \frac{f(x,y)}{f_Y(y)}$ ausrechnen und gucken, ob man die Verteilung kennt

Berechnung von E(X)

0.24) Totale Zerlegung: $E(X) = \int_{\mathbb{R}} E(X|Y=y)\,dP^Y(y)$

↳denn: $E(X) = E(E(X|Y)) = \int_\Omega E(X|Y)\,dP = \int_{\mathbb{R}} E(X|Y=y)\,dP^Y(y)$

0.25) i) Y diskret: $E(X) = \sum_{i\in I} E(X|Y=y_i)\cdot P(Y=y_i)$

ii) Y stetig: $E(X) = \int_{\mathbb{R}} E(X|Y)\cdot f_Y(y)\,dx$

Bsp 0.26) Bergmann 4 Gänge:

1) 2h zur Oberfläche
2) 4h zum Raum zurück
3) 5h zum Raum zurück
4) 5h zur Oberfläche

=> $E(T) = \sum_{i=1}^4 E(T|X=i)\cdot P(X=i) = \frac14\cdot(2+5+(4+E(T))+(5+E(T)))$

Bsp 0.27) Bei gegebenem $\Theta=\vartheta$ sei $X\sim N(\vartheta,\sigma^2)$; $\Theta\sim N(\mu,\tau^2)$

=> $E(X|\Theta=\vartheta) = E(N(\vartheta,\sigma^2)) = \vartheta$

=> $E(X) = E(E(X|\Theta)) = E(\Theta) = \mu$

Wahrscheinlichkeiten durch bedingen berechnen

$P(A) = E(\mathbb{1}_A) = \int \mathbb{1}_A\,dP = \int_A dP$

=> 0.28) $P(A|Y) := E(\mathbb{1}_A|Y)$ (keine ZV!)

0.30) $P(A) = \int P(A|Y=y)\,dP^Y(y)$

↳Bew.: $P(A) = E(\mathbb{1}_A) = E(E(\mathbb{1}_A|Y)) = \int_\Omega E(\mathbb{1}_A|Y)\,dP = \int_{\mathbb{R}} E(\mathbb{1}_A|Y=y)\,dP^Y(y) = \int_{\mathbb{R}} P(A|Y=y)\,dP^Y(y)$

=> Y diskret: $P(A) = \sum_{i\in I} P(A|Y=y_i)\cdot P(Y=y_i)$

Y stetig: $P(A) = \int_{\mathbb{R}} P(A|Y=y)\cdot f_Y(y)\,dy$

Bedingte Verteilung

Bsp: $X\sim Poi(\lambda_1)$, $Y\sim Poi(\lambda_2)$ => $X+Y\sim Poi(\lambda_1+\lambda_2)$

=> $P(X=i|X+Y=j) = \frac{P(\{X=i\}\cap\{X+Y=j\})}{P(\{X+Y=j\})} = \frac{P(\{X=i\})\cdot P(\{Y=j-i\})}{P(\{X+Y=j\})}$

$= \dots = \binom{j}{i}\cdot\left(\frac{\lambda_1}{\lambda_1+\lambda_2}\right)^i\cdot\left(\frac{\lambda_2}{\lambda_1+\lambda_2}\right)^{j-i} \sim Bin\left(j, \frac{\lambda_1}{\lambda_1+\lambda_2}\right)$

=> definiert ein W'Maß

0.33) i) X,Y stetig mit gemeinsamer λ^2-Dichte f:

=> mit $g:\mathbb{R}\to\mathbb{R}$ integrierbar:

$E(g(X)|Y=y) = \int_{\mathbb{R}} g(x)\cdot f(x|y)\,dx$

↳Spezialfall: $P(B|Y=y) = P(X\in B|Y=y) = \int_B f(x|y)\,dx$

ii) X,Y st. unabh., $h:\mathbb{R}^2\to\mathbb{R}$ integrierbar

=> $E(h(X,Y)|Y=y) \overset{st.u.}{=} E(h(X,y))$ Beweis?

Bsp. 0.34) Bei gegebenem $\Theta=\vartheta$ sei $X\sim N(\vartheta,\sigma^2)$; $\Theta\sim N(\mu,\tau^2)$

i) $P(X\le x|\Theta=\vartheta) \overset{0.33\,i)}{=} \int_{-\infty}^x f(t|\vartheta)\,dt = \Phi\left(\frac{x-\vartheta}{\sigma}\right)$ (standardisiert)

ii) $E(X^2|\Theta=\vartheta) \overset{0.33\,i)}{=} \int_{\mathbb{R}} x^2\cdot f(x|\vartheta)\,dx = \sigma^2+\vartheta^2$

↳ da 2. Moment von $N(\vartheta,\sigma^2)$ und $Var(X) = E(X^2)-(E(X))^2$

iii) $E(X^2) \overset{0.24}{=} \int E(X^2|\Theta=\vartheta)\,dP^\Theta(\vartheta) \overset{ii)}{=} \int \sigma^2+\vartheta^2\,dP^\Theta\,\vartheta$

$= \sigma^2\cdot\int dP^\Theta(\vartheta) + \underbrace{\int\vartheta^2\,dP^\Theta(\vartheta)}_{\text{Zweites Moment von } N(\mu,\tau^2)} = \sigma^2\cdot 1 + (\mu^2+\tau^2)$

iv) $Var(X) = E(X^2) - (\underbrace{E(X)}_{0.27})^2 = \sigma^2+\mu^2+\tau^2-\mu^2 = \sigma^2+\tau^2$

0.35) $Y:\Omega\to\mathbb{R}$ diskret: $P(B|Y=y_i) = \frac{P(X^{-1}(B)\cap\{Y=y_i\})}{P(Y=y_i)}$

0.36) $P^X(B) = \int_{\mathbb{R}} P^{X|Y=y}(B)\,dP^Y(y)$

↳Y diskret: $P^X(B) = \sum_{i\in I} P(B|Y=y_i)\cdot P(Y=y_i)$ (0.35)

↳gemeinsame λ^2-Dichte: $P^X(B) = \int_{\mathbb{R}}\left(\int_B f(x|y)\,dx\right) f_Y(y)\,dy$

$E(g(X)|Y=y) = \int g(x)\cdot f(x|y)\,dx$

Bsp 0.37) Schadenanzahl in Zeitraum t: $N_t\sim Poi(\lambda(t))$, $\lambda(t) = a\cdot e^{-t}$

Vertragsdauer: $T\sim Exp(1)$

i) E(N): • $E(N|T=t) = a\cdot e^{-t}$ => $E(N|T) = a\cdot e^{-T}$

$E(N) = E(E(N|T)) = E(a\cdot e^{-T}) = a\cdot E(e^{-T})$

Var(N): $Var(N|T=t) = a\cdot e^{-t}$ => $Var(N|T) = a\cdot e^{-T}$

$Var(N) = E(Var(N|T)) + Var(E(N|T)) = \dots$

=> $E(e^{-kT}) = \int_0^\infty e^{-kt}\cdot e^{-t}\,dt = \dots = \frac{1}{k+1}$ einsetzen

ii) $P(N=0) = \int_{\mathbb{R}} P(N=0|T=t)\,dP^T(t) = \int_{\mathbb{R}} \frac{\lambda(t)^0}{0!}\cdot e^{-\lambda(t)}\,dP^T(t)$

$= \int_{\mathbb{R}} e^{-a\cdot e^{-t}}\,dP^T(t) = \int_{\mathbb{R}} e^{-a\cdot e^{-t}}\cdot e^{-t}\,dt = \left[\frac1a\cdot e^{-ae^{-t}}\right]_0^\infty$

Bedingte Unabhängigkeit

„Risiken sind unabhängig von einander bis auf eine äußere Bedingung"

0.38) X_1, X_2 bedingt unabhängig gegeben Y, falls für alle $y\in Y$ X_1 und X_2 $P^{\cdot|Y=y}$-unabhängig sind

Bsp. 0.39) Bei gegebenem $\Theta=\vartheta$ sei $X\sim N(\vartheta,\sigma^2)$; $\Theta\sim N(\mu,\tau^2)$

$Cov(X_1,X_2) = E(\underbrace{Cov(X_1,X_2|\Theta)}_{=0}) + Cov(E(X_1|\Theta),E(X_2|\Theta))$

$= Cov(E(X_1|\Theta),E(X_2|\Theta)) \overset{0.27}{=} Cov(\Theta,\Theta) = Var(\Theta) = \tau^2$

Bsp 0.40) Frage mit W'keit p korrekt; X ist ZV mit Realisierungen p

$Y = \begin{cases} 1, & \text{falls alle 10 Fragen richtig} \\ 0, & \text{sonst}\end{cases}$

i) $P^X = \frac12(\delta_{\{0\}}+\delta_{\{1\}})$: $P(Y=1) = \int_0^1 p^{10}\,dP^X = \int_0^1 \frac12\cdot(0^{10}+1^{10})\,dp = \frac12$

ii) $P^X = \delta_{\{0,5\}}$: $P(Y=1) = \int_0^1 p^{10}\,dP^X = \int_0^1 0{,}5^{10}\,dp = \frac{1}{1024}$

iii) $P^X = U(0,1)$: $P(Y=1) = \int_0^1 p^{10}\,dP^X = \int_0^1 \mathbb{1}_{[0,1]}(p)\cdot p^{10}\,dp = \left[\frac{1}{11}p^{11}\right]_0^1 = \frac{1}{11}$

Parameterschätzung

·Annahme, dass einzelne Beobachtungen unabhängig sind

=> Modellierung als Realisation eines Zufallsvektors

·Stichprobenraum: Menge aller möglichen Beobachtungen

·$P^X = \{P^X_\vartheta:\vartheta\in\Theta\}$: Menge aller möglichen Verteilungen

↳basierend auf Stichprobe wird W'Verteilung P^X_ϑ genähert

·statistisches Modell: $\mathcal{M} = (\mathcal{X},\mathcal{F},P^X) = (\mathcal{X},\mathcal{F},\{P^X_\vartheta:\vartheta\in\Theta\})$

↳$P^X = \{P^X_\vartheta:\vartheta\in\Theta\}$ ist mindestens zweielementig

↳parametrisch: $\Theta\subseteq\mathbb{R}^k$

↳einparametrisch: $\Theta\subseteq\mathbb{R}$

↳diskret: Stichprobenraum $\mathcal{X}$ ist abzählbar, $\mathcal{F} = \mathcal{P}(\mathcal{X})$

↳stetig: $\mathcal{X}\subseteq\mathbb{R}^n$, $\mathcal{F} = \mathcal{B}^n_{\mathcal{X}}$

Punktschätzer & Eigenschaften

·messbare Abbildung: $\hat\Theta: (\mathcal{X},\mathcal{F})\to(\mathbb{R}^k,\mathcal{B}^k)$

·nicht vom unbekannten Parameter ϑ abhängig

·Schätzwert $\hat\vartheta$ als Realisation von $\hat\Theta = \hat\Theta(X_1,\dots,X_n)$

=> $\underbrace{(\Omega,\mathcal{A},P_\vartheta)}_{\text{Grundraum}} \xrightarrow{(X_1,\dots,X_n)} \underbrace{(\mathcal{X},\mathcal{F},P^X_\vartheta)}_{\text{Stichprobenraum}} \xrightarrow{\hat\Theta} (\mathbb{R}^d,\mathcal{B}^d)$

1.4) i) **erwartungstreu** für ϑ, falls $E_\vartheta(\hat\Theta) = \vartheta$

ii) **Verzerrung/Bias**: $B_{\hat\Theta}(\vartheta) = E_\vartheta(\hat\Theta) - \vartheta$

iii) Folge von Schätzern $(\hat\Theta_n)_{n\in\mathbb{N}}$ **asymptotisch erwartungstreu**: $\lim_{n\to\infty} E_\vartheta(\hat\Theta_n) = \vartheta$

iv) Folge von Schätzern $(\hat\Theta_n)_{n\in\mathbb{N}}$ **konsistent**, falls: $\lim_{n\to\infty} P_\vartheta(|\hat\Theta_n-\vartheta|>\varepsilon) = 0$ $\forall\vartheta\in\Theta$

1.5) hinreichend für **Konsistenz**: asympt. Erwartungstreu und $\lim_{n\to\infty} Var_\vartheta(\hat\Theta_n) = 0$ $\forall\vartheta\in\Theta$

↳Bew?

1.6) **Mittlerer Quadratischer Fehler**

$MSE_\vartheta(\hat\Theta) := E_\vartheta((\hat\Theta-\vartheta)^2) = Var_\vartheta(\hat\Theta) + (B_{\hat\Theta}(\vartheta))^2$

↳Bew: $MSE_\vartheta(\hat\Theta) = E_\vartheta((\hat\Theta-\vartheta)^2) = E_\vartheta((\hat\Theta-E_\vartheta(\hat\Theta)+E_\vartheta(\hat\Theta)-\vartheta)^2)$

$= E_\vartheta[(\hat\Theta-E_\vartheta(\hat\Theta))^2 + 2\cdot(\hat\Theta-E_\vartheta(\hat\Theta))(E_\vartheta(\hat\Theta)-\vartheta) + (E_\vartheta(\hat\Theta)-\vartheta)^2]$

$= \underbrace{E[(\hat\Theta-E(\hat\Theta))^2]}_{=Var(\hat\Theta)} + 2\cdot\underbrace{E(\hat\Theta-E(\hat\Theta))}_{=0}\cdot E(E(\hat\Theta)-\vartheta) + \underbrace{E(E(\hat\Theta)-\vartheta)^2}_{=(B_{\hat\Theta}(\vartheta))^2}$

Bsp. 1.8) $X_1,\dots,X_n\sim U(0,\vartheta)$ iid., $\vartheta>0$

$T_n(X) := \max\{X_1,\dots,X_n\}$, gesucht: $E_\vartheta(T_n)$, $Var_\vartheta(T_n)$, $MSE_\vartheta(T_n)$

1) $P_\vartheta(T_n\le t) = P_\vartheta(X_1\le t,\dots,X_n\le t) = \prod_{i=1}^n P_\vartheta(X_i\le t) = \left(\frac{t}{\vartheta-0}\right)^n$

2) Dichte: $f_\vartheta(t) = \frac{d}{dt}\left(\frac{t}{\vartheta}\right)^n = \frac{n\cdot t^{n-1}}{\vartheta^n}$

=> $E_\vartheta(T_n) = \int_0^\vartheta t\cdot\frac{n\cdot t^{n-1}}{\vartheta^n}\,dt = \left[\frac{n}{\vartheta^n}\cdot\frac{t^{n+1}}{n+1}\right]_0^\vartheta = \frac{n}{n+1}\cdot\vartheta$

=> $B_{T_n}(\vartheta) = E_\vartheta(T_n)-\vartheta = -\frac{1}{n+1}\vartheta$

=> $E_\vartheta(T_n^2) = \int_0^\vartheta t^2\cdot\frac{n\cdot t^{n-1}}{\vartheta^n}\,dt = \left[\frac{n}{\vartheta^n}\cdot\frac{t^{n+2}}{n+2}\right]_0^\vartheta = \frac{n}{n+2}\cdot\vartheta^2$

=> $Var_\vartheta(T_n) = E(T_n^2)-(E(T_n))^2 = \dots = \frac{n}{(n+2)(n+1)^2}\vartheta^2$

=> $MSE_\vartheta(T_n) = Var_\vartheta(T_n) + (B_{T_n}(\vartheta))^2 = \dots = \frac{2\cdot\vartheta^2}{(n+2)(n+1)}$

ii) Konsistenz?

$\lim_{n\to\infty} E_\vartheta(T_n) = \dots = \vartheta$; $\lim_{n\to\infty} Var_\vartheta(T_n) = \dots = 0$ => konsistent

iii) Erwartungstreue Modifikation: $T_n^* = \frac{n+1}{n}\cdot T_n$

Erwartungswert & Varianz schätzen

1.9) $\bar X = \frac1n\cdot\sum_{i=1}^n X_i$ ist erwartungstreuer & konsistenter Schätzer für μ

$S_n^2 = \frac{1}{n-1}\cdot\sum_{i=1}^n(x_i-\bar x_n)^2$ erwartungstreuer & konsistenter Schätzer für σ^2

1.10) Wäre μ bekannt, so ist $\frac1n\sum_{i=1}^n(x_i-\mu)^2$ e-treu für σ^2

Gütekriterien

·Erwartungstreue, ML-Prinzip und MSE sind alles gute Kriterien aber nicht unbedingt miteinander vereinbar

Bsp.: Schätzer für σ^2: $c\cdot\sum_{i=1}^n(X_i-\bar X_n)^2$

$c=\frac{1}{n-1}$: e-treuer Schätzer

$c=\frac1n$: ML-Schätzer

$c=\frac{1}{n+1}$: minimiert MSE

gleichmäßig bester Schätzer

•$\hat\Theta^*$ heißt glm. bester Schätzer, falls:

− $\hat\Theta^*$ ist e-treu

− für alle e-treuen Schätzer $\hat\Theta$ gilt: $Var_\vartheta(\hat\Theta)\ge Var_\vartheta(\hat\Theta^*)$

Satz von Student

− $X_1,\dots,X_n\overset{iid}{\sim}N(\mu,\sigma^2)$ mit $\bar X = \frac1n\sum_{i=1}^n X_i$ | $S_n^2 = \frac{1}{n-1}\sum_{i=1}^n(X_i-\bar X_n)^2$

i) $\bar X_n\sim N(\mu,\frac{\sigma^2}{n})$

ii) $(n-1)\frac{S_n^2}{\sigma^2}\sim\chi^2_{n-1}$

iii) $\bar X_n$ und S_n^2 sind stoch. unabh.

iv) $T_n = \sqrt{n}\cdot\frac{X_n-\mu}{S_n}\sim t_{n-1}$ mit $S_n = \sqrt{S_n^2}$

Maximum-Likelihood-Schätzung

ML-Prinzip

Gegeben: statist. Standardmodell: $\mathcal{M} = (\mathcal{X},\mathcal{F},\{P^k_\vartheta:\vartheta\in\Theta\})$

↳d.h. parametrisch ($\Theta\subseteq\mathbb{R}^k$) und $\{P^X_\vartheta:\vartheta\in\Theta\}$ durch Zählmaß oder λ-Maß dominiert mit Dichten $f_\vartheta(x)$

2.1) Likelihood-Funktion: $L:\mathcal{X}\times\Theta\to[0,\infty)$, $(x,\vartheta)\to L(x,\vartheta) = c(x)\cdot f_\vartheta(x)$

2.2) Log-Likelihood: $\ell_x:\Theta\to\bar{\mathbb{R}}$, $\vartheta\mapsto\begin{cases}\ln(L_x(\vartheta)), & L_x(\vartheta)>0 \\ -\infty, & \text{sonst}\end{cases}$

Bsp: $X\sim Bin(n,\vartheta)$

=> stat. Modell: $(\{0,\dots,n\}, \mathcal{P}(\{0,\dots,n\}), \{Bin(n,\vartheta):\vartheta\in[0,1]\})$

$f_\vartheta(x) = \binom{n}{x}\cdot\vartheta^x\cdot(1-\vartheta)^{n-x}$

=> $L_x(\vartheta) = \vartheta^x\cdot(1-\vartheta)^{n-x}$ mit $c(x) = \frac{1}{\binom{n}{x}}$

=> $\ell_x(\vartheta) = \ln(L_x(\vartheta)) = x\cdot\ln(\vartheta) + (n-x)\cdot\ln(1-\vartheta)$

$= x\cdot\ln\left(\frac{\vartheta}{1-\vartheta}\right) + n\cdot\ln(1-\vartheta)$

·Ableiten und =0 liefert: $\hat\vartheta = \frac{x}{n}$, $\ell''_x(\frac xn)<0$ ✓

Bsp: $X_1,\dots,X_n\overset{iid}{\sim}N(\mu,\sigma^2)$

• stat. Modell: $(\mathbb{R}^n,\mathcal{B}^n,\{\bigotimes_{i=1}^n N(\mu,\sigma^2):\mu\in\mathbb{R},\sigma^2>0\})$

• unabhängig, deswegen Produkt der Dichten:

$f_{\mu,\sigma^2}(x) = \prod_{i=1}^n\frac{1}{\sqrt{2\pi\sigma^2}}\cdot\exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right) = \frac{1}{(2\pi\sigma^2)^{n/2}}\cdot\exp\left(-\frac{\sum_{i=1}^n(x_i-\mu)^2}{2\sigma^2}\right)$

=> $L_x(\mu,\sigma^2) = \frac{1}{\sigma^n}\cdot\exp\left(-\frac{1}{2\sigma^2}\cdot\sum_{i=1}^n(x_i-\mu)^2\right)$ mit $c(x) = (2\pi)^{n/2}$

=> $\ell_x(\mu,\sigma^2) = -\frac n2\cdot\ln(\sigma^2) - \frac{1}{2\sigma^2}\cdot\sum_{i=1}^n(x_i-\mu)^2$

=> Für ML-Schätzer $\hat\vartheta(x) = (\hat\mu(x),\hat\sigma^2(x))$:

·Gradient =0 setzen, Hessematrix muss negativ definit sein

·Randverhalten untersuchen auf $\mathbb{R}\times\mathbb{R}_{>0}$

Bsp: $X_1,\dots,X_n\sim U(0,\vartheta)$

• stat. Modell: $([0,\infty)^n, \mathcal{B}^n_{[0,\infty)}, \{\bigotimes_{i=1}^n U(0,\vartheta): n>0\})$

• $f_\vartheta(x) = \prod_{i=1}^n\frac1\vartheta\cdot\mathbb{1}_{[0,\vartheta]}(x) = \frac{1}{\vartheta^n}\cdot\prod_{i=1}^n\mathbb{1}_{[0,\vartheta]}(x)$

=> $L_x(\vartheta) = \frac{1}{\vartheta^n}\cdot\mathbb{1}_{[\max(x_1,\dots,x_n),\infty)}(\vartheta)$

=> ML-Schätzer $\hat\vartheta = \max(X_1,\dots,X_n)$ offensichtlich

↳nicht e-treu, aber asypt. e-treu

2.4) ML-Schätzer

$\hat\vartheta:\mathcal{X}\to\Theta\subseteq\mathbb{R}^k$ ist ML-Schätzer, falls

$L_x(\hat\vartheta(x)) = \max_{\vartheta\in\Theta} L_x(\vartheta)$ bzw. $\ell_x(\hat\vartheta(x)) = \max_{\vartheta\in\Theta}\ell_x(\vartheta)$

=> d.h. Ableitung (oder Gradient) von log-Likelihood =0

=> 2. Ableitung muss negativ sein / Hessematrix negativ definit

2.7) Invarianzprinzip für ML-Schätzer

=> Injektive, messbare Transformationen übertragen sich auf ML-Schätzer

·$g:\Theta\to\mathbb{R}^k$ messbar, injektiv und $\hat\vartheta$ ML-Schätzer für $\vartheta\in\Theta$

=> Dann ist $\hat\eta = g(\hat\vartheta)$ ML-Schätzer für $\eta = g(\vartheta)$

↳bzgl. der Likelihood-Fkt. M_x von $g(\vartheta)$

=> **Plug-In-Methode**: Einsetzen von $\hat\vartheta$ in $g(\vartheta)$

Bsp.: $X_1,\dots,X_{100}\sim Bin(1,\vartheta)$, Bekannt: $\bar X_{100}$ ist ML-Schätzer für ϑ

=> $Var(\bar X_{100}) = \frac{1}{100^2}\cdot\sum_{i=1}^{100}Var(X_1) = \frac{\vartheta\cdot(1-\vartheta)}{100}$ => $\hat\sigma^2 = \frac{\bar X_{100}(1-\bar X_{100})}{100}$

Eigenschaften von ML-Schätzern

•Im Folgenden betrachten wir reguläre Verteilungsfamilien:

↳Dichte hat für alle ϑ denselben Träger

↳Dichte zweimal stetig diffbar

2.13) **Scorefunktion**

$u_x(\vartheta) = \frac{d}{d\vartheta}\ell_x(\vartheta) = \frac{\frac{d}{d\vartheta}f_\vartheta(x)}{f_\vartheta(x)}$ Änderung der Dichte in Bezug auf Wert der Dichte

↳Es gilt: $E(u_X(\vartheta)) = 0$

↳Bew: $E(u_X(\vartheta)) = \int u_x(\vartheta)\cdot f_\vartheta(x)\,d\mu = \int\frac{d}{d\vartheta}f_\vartheta(x)\,d\mu = \frac{d}{d\vartheta}\cdot\int f_\vartheta(x)\,d\mu = \frac{d}{d\vartheta}1 = 0$

2.15) Fischer-Information (ist groß, wenn Varianz klein ist)

$I(\vartheta) = E(u_X(\vartheta)\cdot(u_X(\vartheta))^T)$ ist k×k-Matrix

$= Var(u(X,\vartheta))$

$= -E_\vartheta\left[\left(\frac{\partial^2}{\partial\vartheta_i\partial\vartheta_j}\ell_X(\vartheta)\right)_{1\le i,j\le k}\right] = -E(u'_X(\vartheta))$

↳mit $X = (X_1,\dots,X_n)$ iid: $I_X(\vartheta) = n\cdot I_{X_1}(\vartheta)$

↳Bew: $f^X_\vartheta(x) = \prod_{i=1}^n f_\vartheta(x_i)$

Bsp.: $X\sim Bin(1,p)$

=> $L_x(p) = p^x\cdot(1-p)^{1-x}$, $\ell_x(p) = x\cdot\ln(p) + (1-x)\cdot\ln(1-p)$

$u_x(p) = \ell'_x(p) = \frac xp - \frac{1-x}{1-p}$, $\ell''_x(p) = -\frac{x}{p^2} - \frac{(1-x)}{(1-p)^2}$

$I_x(p) = -E(\ell''_x(p)) = \frac{1}{p\cdot(1-p)}$

Bsp: $X\sim Poi(\lambda)$ => ... => $u_x(\lambda) = -1+\frac x\lambda$ => ... => $I_x(\lambda) = \frac1\lambda$

2.21) ?

2.22) X_n iid mit dreimal stetig diffbarer Dichte $f_\vartheta(x)$

zusätzlich gilt mit messbarer Fkt $M:\mathcal{X}\to[0,\infty)$: $|\ell'''_x(\vartheta)|\le M(x)$

=> Dann: $\sqrt{n}\cdot(\hat\vartheta_n-\vartheta)\xrightarrow[n\to\infty]{d}N(0,(I_{X_1}(\vartheta))^{-1})$

=> $\hat\vartheta_n\overset{as.}{\sim}N\left(\vartheta,\frac{1}{I_{(X_1,\dots,X_n)}(\vartheta)}\right)$

− mit messbarer, injektiver Abbildung g:

$\sqrt{n}(g(\hat\vartheta_n)-g(\vartheta))\xrightarrow[n\to\infty]{d}N(0,D^T\cdot(I_{X_1}(\vartheta))^{-1}\cdot D)$

mit $D = \left(\frac{dg_i}{d\vartheta_j}\right)_{1\le i,j\le k}$

=> im 1-dim.: $g(\hat\vartheta)\overset{as.}{\sim}N\left(g(\vartheta), g'(\vartheta)\cdot(I_x(\vartheta))^{-1}\cdot g'(\vartheta)\cdot\frac1n\right)$

Bsp: $X_1,\dots,X_n\overset{iid}{\sim}N(\mu,\sigma^2)$, μ,σ^2 unbekannt

i) Hessematrix der Dichte berechnen

ii) $I_X(\mu,\sigma^2) = -E(H_X(\mu,\sigma^2)) = \dots = \begin{pmatrix} n/\sigma^2 & 0 \\ 0 & n/(2\sigma^4)\end{pmatrix}$

iii) $\hat\sigma^2_n = \frac1n\cdot\sum_{i=1}^n(X_i-\bar X_n)^2$ ist ML-Schätzer für σ^2

iv) Plug-In-Methode: $g(\hat\sigma^2_n) = \sqrt{\hat\sigma^2_n}$ ist ML-Schätzer für σ

v) $I_{X_1}(\sigma^2) = \frac{1}{2\sigma^4}$ keine Matrix da hier nur σ^2 interessiert

vi) $\sqrt{n}(\hat\sigma^2_n-\sigma^2)\xrightarrow[n\to\infty]{d}N(0,2\sigma^4)$ => $\hat\sigma^2_n\overset{as.}{\sim}N\left(\sigma^2,\frac{2\sigma^4}{n}\right)$

vii) $\sqrt{\hat\sigma^2_n}\sim N\left(\sigma,\frac{\sigma^2}{2n}\right)$, denn $g'(\sigma^2) = (\sqrt{\sigma^2})' = \frac{1}{2\sigma}$

Bereichsschätzung

3.3) Konfidenzbereich K(x) abhängig von Stichprobe X

$K:\mathcal{X}\longrightarrow\mathcal{P}(\Theta)$ mit:

i) K ist nicht abhängig vom wahren Parameter Θ

ii) messbar: $A(\vartheta) = \{x\in\mathcal{X}:\vartheta\in K(x)\}\in\mathcal{B}^n$ (Annahmebereich)

iii) $P^X_\vartheta(\vartheta\in K(X)) = P^X_\vartheta(X\in A(\vartheta))\ge 1-\alpha$

3.5) i) Formal wäre $K(x)=\Theta$ ein Schätzer

↳aber der Bereich soll zum Niveau 1−α möglichst klein sein

ii) Falls $\Theta\subseteq\mathbb{R}$: $K(x) = [a(x);b(x)]$ heißt Konfidenzintervall

iii) ϑ ist fest und K(x) ist zufällig, abhängig von Stichprobe x

Exakte Konfidenzbereiche

3.6) **$N(\mu,\sigma^2)$-Verteilung**

=> statistisches Modell: $(\mathbb{R}^n,\mathcal{B}^n,\{\bigotimes_{i=1}^n N(\mu,\sigma^2),\mu\in\mathbb{R},\sigma^2>0\})$

i) **Schätzung für $\mu\in\mathbb{R}$, $\sigma_0^2>0$ bekannt**

=> $K(x) = \left[\bar x_n - u_{1-\frac\alpha2}\cdot\frac{\sigma_0}{\sqrt n}; \bar x_n + u_{1-\frac\alpha2}\cdot\frac{\sigma_0}{\sqrt n}\right]$

mit $u_{1-\frac\alpha2}\,\hat=\,(1-\frac\alpha2)$-Quantil der N(0,1)-Verteilung

↳Bew: $P^X_\mu(\mu\in K(X)) = 1-\alpha$ nachrechnen mit $\frac{\bar X_n-\mu}{\sigma/\sqrt n}\sim N(0,1)$

ii) **Schätzung für $\mu\in\mathbb{R}$, $\sigma^2>0$ unbekannt**

=> $K(x) = \left[\bar x - t_{n-1,1-\frac\alpha2}\cdot\frac{s_n}{\sqrt n}; \bar x + t_{n-1,1-\frac\alpha2}\cdot\frac{s_n}{\sqrt n}\right]$

mit $t_{n-1,1-\frac\alpha2}\,\hat=\,(1-\frac\alpha2)$-Quantil der t_{n-1}-Verteilung

und $s_n = \sqrt{\frac{1}{n-1}\cdot\sum_{i=1}^n(x_i-\bar x_n)^2}$

↳Bew: wie bei i) und mit Satz von Student (Ende Kap. 1)

iii) **Schätzung für $\sigma^2>0$**

=> $K(x) = \left[\frac{(n-1)\cdot s_n^2}{\chi^2_{n-1,1-\frac\alpha2}}; \frac{(n-1)\cdot s_n^2}{\chi^2_{n-1,\frac\alpha2}}\right]$ mit $S_n^2 = \frac{1}{n-1}\sum_{i=1}^n(x_i-\bar x_n)^2$

3.7) **Bin(n,p)-Verteilung**

=> Binomialmodell $(\{0,\dots,n\},\mathcal{P}(\{0,\dots,n\}),\{Bin(n,p),p\in(0,1)\})$

i) Konfidenzintervall für $p\in(0,1)$:

$K(x) = (\underbrace{\beta_{x,n-x+1,\frac\alpha2}}_{\beta(x,n-x+1)\text{-Vert.}}; \underbrace{\beta_{n-x,x+1,\frac\alpha2}}_{\beta(n-x,x+1)\text{-Vert.}})$ Quantilen der β(a,b)-Vert „qbeta(α/2,a,b)"

Approximative Konfidenzbereiche mit Tschebyschef

− ein parametrische stat. Modelle

3.8) $X_1,\dots,X_n$ iid. mit $E_\vartheta(X_1)=\vartheta$ und einer oberen Schranke σ^2_{max} für $Var(X_1)$

=> $K(x) = \left[\bar x_n - \frac{\sigma_{max}}{\sqrt{n\cdot\alpha}}, \bar x_n + \frac{\sigma_{max}}{\sqrt{n\cdot\alpha}}\right]$

ist Konfidenzbereich zum Niveau 1−α

↳Bew: $P_\vartheta\left(\bar x_n - \frac{\sigma_{max}}{\sqrt{n\cdot\alpha}}\le\vartheta\le\bar x_n + \frac{\sigma_{max}}{\sqrt{n\cdot\alpha}}\right)$

$= 1 - P_\vartheta\left(|\bar X_n-\vartheta|>\frac{\sigma_{max}}{\sqrt{n\alpha}}\right) \underset{\text{Tschebyschef}}{\ge} 1 - \frac{n\cdot\alpha\cdot Var(\bar X_n)}{\sigma^2_{max}}\ge 1-\alpha$

Bsp: $X_1,\dots,X_n\overset{iid}{\sim}Poi(\lambda)$, $E(X_1)=\lambda$, $\sigma^2_{max}=25$ => $\sigma_{max}=5$

=> 95% K.i.: Einsetzen => $K(x) = [14{,}2; 15{,}8]$

Bsp: $X_1,\dots,X_n\overset{iid}{\sim}Bin(1,p)$, $E_p(X_1)=p$, $\sigma^2_{max} = p\cdot(1-p)\le 0{,}25$

·Umfrage unter 1000; 200 stimmen zu

i) mit Tschebyschef: einsetzen

ii) ZGWS: $\frac{\bar X_n-\mu}{\sigma/\sqrt n}\xrightarrow{n\to\infty}N(0,1)$ => $\bar X_n\xrightarrow{n\to\infty}N(\mu,\frac{\sigma^2}{n}) = N(p,\frac{p(1-p)}{n})$

=> $K(x) = \left[\bar X_n - u_{0{,}975}\cdot\frac{\sqrt{X_n\cdot(1-X_n)}}{\sqrt n}\right]$

Approximative Bereiche mit ML-Theorie

3.11) $X_1,\dots,X_n\overset{iid}{\sim}P^{X_1}_\vartheta$, $(\hat\vartheta_n)_{n\in\mathbb{N}}$ Folge konsistenter ML-Schätzer

mit $\sqrt n(\hat\vartheta_n-\vartheta)\xrightarrow{n\to\infty}N(0,(I_{X_1}(\vartheta))^{-1})$ Satz 2.22)

=> Da dann $\sqrt n\cdot\sqrt{I_{X_1}(\vartheta)}\cdot(\hat\vartheta_n-\vartheta)\overset{as}{\sim}N(0,1)$:

$K(x) = \left[\hat\vartheta_n - \frac{u_{1-\alpha/2}}{\sqrt{n\cdot I_{X_1}(\hat\vartheta)}}; \hat\vartheta_n - \frac{u_{1-\alpha/2}}{\sqrt{n\cdot I_{X_1}(\hat\vartheta)}}\right]$ zum Niveau 1−α

↳Für $I_{X_1}(\hat\vartheta_n)$: $I_{X_1}(\hat\vartheta_n) = -\frac{d^2}{d\vartheta^2}\ell_x(\hat\vartheta_n)$

Bsp: $X_1,\dots,X_n\overset{iid}{\sim}Bin(1,p)$, $E_p(X_1)=p$, $\sigma^2_{max} = p\cdot(1-p)\le 0{,}25$

↳ML-Schätzer für p: $\bar X_n$; $I_{X_1}(p) = \frac{1}{p\cdot(1-p)}$ Bsp. 2.20

↳95%-Ki zur Stichprobe mit $\bar x_{1000} = 0{,}2$

=> $I_{X_1}(\bar x_{1000})\approx\frac{1}{0{,}2\cdot 0{,}8}$ einsetzen

Normalverteilungstheorie

4.1) Varianz-Kovarianzmatrix für Zufallsvektor $X = (X_1,\dots,X_n)^T$

Σ $V_P(X) = \left(E_P[(X_i-E_P(X_i))\cdot(X_j-E_P(X_j))^T]\right)_{1\le i,j\le n}\in\mathbb{R}^{n\times n}$

$= (Cov_P(X_i,X_j))_{1\le i,j\le n} = \Sigma$

↳immer positiv-semidefinit denn $a^T\cdot V_P(X)\cdot a\ge 0$ $\forall a\in\mathbb{R}^n$

↳immer symmetrisch

↳$v_{ij}\le\max\{v_{ii}\}$, denn $|Cov(X_i,X_j)|\overset{C.S.}{\le}\sqrt{Var(X_i)\cdot Var(X_j)}\le\max\{v_{ii}\}$

↳$E_P(AX+b) = A\cdot E_P(X)+b$

↳$V_P(AX+b) = A\cdot V_P(X)\cdot A^T$

4.5) Kovarianzmatrix $X = (X_1,\dots,X_n)^T$, $Y = (Y_1,\dots,Y_m)^T$

=> $Cov_P(X,Y) = \left(E_P[(X_i-E_P(X_i))\cdot(Y_j-E_P(Y_j))]\right)_{1\le i\le n,1\le j\le m}\in\mathbb{R}^{n\times m}$

$= E(X\cdot Y^T) - E(X)\cdot(E(Y))^T$

↳X,Y unkorreliert: $Cov_P(X,Y) = \mathbb{0}$

4.7) X,Y haben gleiche Dimension, dann:

i) $E(X+Y) = E(X)+E(Y)$

ii) X,Y unkorreliert => $V_P(X+Y) = V_P(X)+V_P(Y)$

↳da dann $E(X\cdot Y) = E(X)\cdot E(Y)$

Mehrdimensionale Normalverteilung

$X\sim N(\mu,\Sigma)$: $f(x) = \frac{1}{\sqrt{(2\pi)^n\cdot\det(\Sigma)}}\cdot\exp\left(-\frac12\cdot(x-\mu)^T\cdot\Sigma^{-1}\cdot(x-\mu)\right)$

• Σ ist positiv definit => $\det(\Sigma)>0$

• standardnormalverteilt: $N(0,I_n)$ mit I_n: Einheitsmatrix

·Normiertheit prüfen (Beispiel von $N(0,I_n)$)

i) Integral über Dichte

ii) Dichte als Produkt der 1-dim. Dichten schreiben

iii) Produkt & Integralzeichen mit Fubini vertauschen

·$X\sim N(0,I_n)$ <=> $X_1,\dots,X_n\overset{iid}{\sim}N(0,1)$

4.10) $X\sim N(0,I_n)$, $\mu\in\mathbb{R}^n$, $A\in\mathbb{R}^{n\times n}$ mit $\Sigma := AA^T$

=> $AX+\mu\sim N(\mu,\Sigma)$

↳Bew: mit Transformationsformel:

$T(X) = AX+\mu$ => $A^{-1}(X-\mu)$, es ergibt sich: $J_{T^{-1}}(x) = A^{-1}$

=> Dichte von T(X): $h = f\circ T^{-1}(x)\cdot|\det(J_{T^{-1}}(x))|$

mit f der Dichte der $N(0,I_n)$-Verteilung

↳$E_P(AX+\mu) = A\cdot E_P(X)+\mu = \mu$

↳$V_P(AX+\mu) = A\cdot V_P(X)\cdot A^T = AA^T = \Sigma$

4.11) i) Standardisierung (Umkehrung von 4.10): $Y\sim N(\mu,\Sigma)$, $\Sigma = AA^T$

=> $A^{-1}(Y-\mu)\sim N(0,I_n)$

4.12) $N(0,I_n) = \bigotimes_{i=1}^n N(0,1)$ ist invariant unter Drehung/Spiegelung

↳Bew: mit Satz 4.10 und es gilt für jede Orthogonalmatrix: $O^T = O^{-1}$

4.13) $Y\sim N(\mu,\Sigma)$, $\mu\in\mathbb{R}^n$, $\Sigma\in\mathbb{R}^{n\times n}$; $C\in\mathbb{R}^{k\times n}$, $d\in\mathbb{R}^k$

=> $CY+d\sim N(C\mu+d, C\Sigma C^T)$

4.14) i) $Y\sim N_n(\mu,\Sigma)$ <=> $\forall c\in\mathbb{R}^n$: $c^T\cdot Y = c_1Y_1+\dots+c_nY_n\sim N(\mu,\sigma^2)$

ii) $Y\sim N_n(\mu,\Sigma)$ => $Y_i\sim N_1(\mu_i,\sigma_{ii}^2)$

4.15) **Wenn X,Y normalverteilt: X,Y st.u. <=> X,Y unkorreliert**

χ^2-Verteilung

4.16) Sei $X = (X_1,\dots,X_n)^T\sim N(\vec0,I_n)$ => $\sum_{i=1}^n X_i^2 = \chi^2_n$

↳d.h. $X_1,\dots,X_n\overset{iid}{\sim}N(0,1)$

Testtheorie

·statistisches Modell $(\mathcal{X},\mathcal{F},P^X)$ mit $P^X = \{P^X_\vartheta:\vartheta\in\Theta\}$

↳parametrisch: $\Theta\subseteq\mathbb{R}^k$

↳einparametrisch: z.B. $P^X = \{Bin(n,\vartheta):\vartheta\in(0,1)\}$

↳zweiparametrisch: z.B. $P^X = \{N(\mu,\sigma^2):\vartheta = (\mu,\sigma^2)\in\mathbb{R}\times(0,\infty)\}$

↳nicht-parametrisch: z.B. $P^X = \{P^X$ auf $(\mathbb{R},\mathcal{B})$ mit $E_P(x)=1\}$

·Entscheidungsproblem

↳Zerlege P^X in Teilmengen P^X_0 & P^X_1 bzw Θ in Θ_0 & Θ_1

=> $H_0: P^X_\vartheta\in P^X_0$ bzw $H_0:\vartheta\in\Theta_0$ ϑ ist wahrer Parameter

$H_0: P^X_\vartheta\in P^X_1$ bzw $H_0:\vartheta\in\Theta_1$ bzw P^X_ϑ wahre Verteilung

↳„einfache" Hypothese: $|\Theta_0| = 1 = |\Theta_1|$

„zusammengesetzte" Hypotese: $|\Theta_0|>1$, $|\Theta_1|>1$

Arten von Testproblemen:

·Alternativtestproblem: $H_0:\vartheta=\vartheta_0$, $H_1:\vartheta=\vartheta_1$

·zweiseitiges Testproblem: $H_0:\vartheta=\vartheta_0$, $H_1:\vartheta\ne\vartheta_0$

·einseitiges Testproblem

Nicht-randomisierte Tests

=> ist eine messbare Abbildung $\varphi:\mathcal{X}\to\{0,1\}$

↳$\varphi(x)=0$: Verdacht auf Alternative lässt sich nicht rechtfertigen

↳$\varphi(x)=1$: Verdacht auf Alternative lässt sich rechtfertigen

Signifikanzmenge $S := \{x\in\mathcal{X}:\varphi(x)=1\}$

↳alle Beobachtungen für die H_1 angenommen wird

Entsch. \ tatsäch.	H_0 ist richtig	H_1 ist richtig
$\varphi(x)=0$	✓	2. Art
$\varphi(x)=1$	1. Art	✓

Fehler 1. Art ist schlimmer

5.6) i) **Gütefunktion** $G_\varphi(\vartheta) = E^X_\vartheta(\varphi) = P^X_\vartheta(\varphi=1) = P^X_\vartheta(S)$

↳gibt für jedes $\vartheta\in\Theta$ die W'keit an, H_1 anzunehmen

ii) Stärke/Schärfe $\beta(\vartheta) = 1-G_\varphi(\vartheta)$

↳W'keit für Fehler 2. Art (H_0 annehmen obwohl H_1 richtig ist)

5.7) **Niveaugleichung** $\alpha\in(0,1)$; $S = \{x\in\mathcal{X}:\varphi(x)=1\}$

$\sup_{\vartheta\in\Theta_0}G_\varphi(\vartheta) = \sup_{\vartheta\in\Theta_0}E^X_\vartheta(\varphi) = \sup_{\vartheta\in\Theta_0}P^X_\vartheta(S)\le\alpha$

↳Wenn H_0 wahr ist wird W'keit, H_1 anzunehmen, begrenzt

Bsp. einseitiger Gauß-Test: $X_1,\dots,X_n\sim N(\mu,\sigma_0^2)$; μ unbekannt

↳statistisches Modell: $(\mathbb{R}^n,\mathcal{B}^n,\{\bigotimes_{i=1}^n N(\mu,\sigma_0^2):\mu\in\mathbb{R}\})$

↳Testproblem: $H_0:\mu\le\mu_0$; $H_1:\mu>\mu_0$

↳Schätzer für μ: $\bar X_n = \frac1n\cdot\sum_{i=1}^n X_i\sim N(\mu,\frac{\sigma_0^2}{n})$

↳Teststatistik: standardisieren: $T(X) = \frac{\bar X_n-\mu_0}{\sigma_0/\sqrt n}\sim N(0,1)$

↳Test: $\varphi_c(x) = \begin{cases}1 & T(x)>c \\ 0 & \text{sonst}\end{cases}$

↳Gütefkt: $G_{\varphi_c}(\mu) = P_\mu(T(X)>c) = P\left(\frac{X_n-\mu_0}{\sigma_0/\sqrt n}>c\right)$

$= P\left(\frac{X_n-\mu+\mu-\mu_0}{\sigma_0/\sqrt n}>c\right) = P\left(\frac{X_n-\mu}{\sigma_0/\sqrt n}>c-\frac{\mu-\mu_0}{\sigma_0/\sqrt n}\right)$

$= 1-\Phi\left(c-\frac{\mu-\mu_0}{\sigma_0/\sqrt n}\right)$

↳streng m. wachsend in μ, $\lim_{\mu\to\infty}G_{\varphi_c}(\mu) = 1$, $\lim_{\mu\to-\infty}G_{\varphi_c}(\mu) = 0$

↳c bestimmen: $\alpha = \sup_{\mu\le\mu_0}G_{\varphi_c}(\mu) = 1-\Phi(c)$ => $c = \Phi^{-1}(1-\alpha)$

↳Fehler 2. Art: $\sup_{\mu>\mu_0}(1-G_{\varphi_c}(\mu)) = 1-G_{\mu_c}(\mu_0) = 1-\alpha$

Bsp: zweiseitiger Gauß-Test (analog zum einseitigen)

↳Test: $\varphi_c(X) = \begin{cases}1, & |T(X)| = \left|\frac{\bar X_n-\mu_0}{\sigma_0/\sqrt n}\right|>c \\ 0, & \text{sonst}\end{cases}$

↳Gütefkt: $G_{\varphi_c}(\mu) = 1-P\left(-c\le\frac{\bar X_n-\mu_0}{\sigma_0/\sqrt n}\le c\right) = 1-P\left(-c\le\frac{\bar X_n-\mu+\mu+\mu_0}{\sigma_0/\sqrt n}\le c\right)$

$= \dots = 1-\Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt n}+c\right)+\Phi\left(\frac{\mu_0-\mu}{\sigma_0/\sqrt n}-c\right)$

↳$\lim_{\mu\to\pm\infty}G_{\varphi_c}(\mu) = 1$

↳$\alpha = \sup_{\mu=\mu_0}G_{\varphi_c}(\mu) = G_{\varphi_c}(\mu_0) = 1-\Phi(c)+\Phi(-c) = 2-2\Phi(c)$

=> $c = \Phi^{-1}(1-\frac\alpha2)$

Bsp: t-test: $X_i\sim N(\mu,\sigma^2)$; Test auf μ; σ^2 unbekannt

↳Analog zu einseitigem Gauß (s.o.)

↳$T(X) = \frac{\bar X_n-\mu_0}{S_n/\sqrt n}$ mit $S_n = \sqrt{\frac{1}{n-1}\cdot\sum_{i=1}^n(X_i-\bar X_n)^2}$

i) $H_0:\mu\le\mu_0$; $H_1:\mu>\mu_0$ bzw $H_0:\mu\ge\mu_0$; $H_1:\mu<\mu_0$

=> $\varphi(x_1,\dots,x_n) = \begin{cases}1, & T(X)>t_{n-1,1-\alpha} \\ 0, & \text{sonst}\end{cases}$ bzw $<t_{n-1,\alpha}$

ii) $H_0:\mu=\mu_0$; $H_1:\mu\ne\mu_0$

=> $\varphi(x_1,\dots,x_n) = \begin{cases}1, & |T(X)|>t_{n-1,1-\frac\alpha2} \\ 0, & \text{sonst}\end{cases}$

Bsp: Varianztest: $X_i\sim N(\mu,\sigma^2)$, Test auf σ^2

↳$T(X) = (n-1)\cdot\frac{S_n^2}{\sigma_0^2}$ ist für $\sigma=\sigma_0$ χ^2_{n-1}-verteilt

↳mit $S_n^2 = \frac{1}{n-1}\cdot\sum_{i=1}^n(X_i-\bar X_n)^2$

i) $H_0:\sigma\le\sigma_0$; $H_1:\sigma>\sigma_0$ bzw $H_0:\sigma\ge\sigma_0$; $H_1:\sigma<\sigma_0$

↳$\varphi(x) = \begin{cases}1, & \text{falls } T(x)>\chi^2_{n-1,1-\alpha} \\ 0, & \text{sonst}\end{cases}$ bzw $<\chi^2_{n-1,\alpha}$

ii) $H_0:\sigma=\sigma_0$; $H_1:\sigma\ne\sigma_0$

↳$\varphi(x) = \begin{cases}1, & \text{falls } T(x)<\chi^2_{n-1,\alpha/2} \text{ oder } T(x)>\chi^2_{n-1,1-\frac\alpha2} \\ 0, & \text{sonst}\end{cases}$

Exponentialverteilung:

betrachte z.B. $\frac1\lambda\le\frac{1}{\lambda_0}$ statt $\lambda\ge\lambda_0$

Randomisierte statistische Tests

Bsp: $X_1,\dots,X_n \overset{iid}{\sim} Bin(1,\vartheta)$, ϑ_0 gegeben

↳ stat. Modell: $(\{0,1\}^n, P(\{0,1\}^n), \{\bigotimes_{i=1}^n Bin(1,\vartheta): \vartheta\in(0,1)\})$

↳ Testproblem: $H_0: \vartheta\le\vartheta_0$, $H_1: \vartheta>\vartheta_0$

↳ Teststatistik: $T(X_1,\dots,X_n)=\sum_{i=1}^n X_i \overset{\vartheta=\vartheta_0}{\sim} Bin(n,\vartheta_0)$

↳ Nichtrand. Test: $\varphi_c(X) = \begin{cases}1, & T(x)>c\\ 0, & \text{sonst}\end{cases}$

↳ Gütefkt: $G_{\varphi_c}(\vartheta)=P_\vartheta(\varphi_c(x)=1)=P(\sum_{i=1}^n X_i>c)=P_\vartheta^{\sum_{i=1}^n X_i}((c,n])$

↳ Niveaugl. $\alpha=\sup_{\vartheta\le\vartheta_0} G_{\varphi_c}(\vartheta) = P_{\vartheta_0}^{\sum_{i=1}^n X_i}((c,n])$

↳ nicht immer lösbar

5.12) randomisierter Test: $\varphi: \mathcal{X}\to[0,1]$

↳ Verwerfungsbereich $S=\{x\in\mathcal X:\varphi(x)=1\}$

↳ Randomisierungsbereich $R=\{x\in\mathcal X: 0<\varphi(x)<1\}$

↳ Annahmebereich $A=\{x\in\mathcal X:\varphi(x)=0\}$

=> $\varphi(x)$ ist die W'keit, dass man sich aufgrund von x. für H_1 entscheidet

5.13) Gütefunktion $G_\varphi(\vartheta)=E_\vartheta(\varphi(x))$

=> Erwartete W'keit, dass Ho verworfen wird, wenn ϑ der wahre Parameter ist

5.15) Test für $H_0:\vartheta\le\vartheta_0$; $H_1:\vartheta>\vartheta_0$

=> $\varphi_{c,\gamma}(x)=\begin{cases}1, & T(x)>c\\ \gamma, & T(x)=c\\ 0, & T(x)<c\end{cases}$ ← man macht noch ein Zufallsexperiment, das mit W'keit γ das Ergebnis 1 hat => $Y\sim Bin(1,\gamma)$

5.16) gibt immer einen Test, der die Niveaugleichung $G_{\varphi_{c,\gamma}}(\vartheta_0)=E^X_{\vartheta_0}(\varphi_{c,\gamma})=\alpha$ erfüllt

↳ Konstruktion:

i) $c:=\inf\{t\in\mathbb R\mid P_{\vartheta_0}(T(x)\le t)\ge 1-\alpha\}$

↳ kleinste (1-α) Quantil der Verteilung von T(x), wenn $\vartheta=\vartheta_0$

ii) $\gamma := \begin{cases}\frac{\alpha-P_{\vartheta_0}(T(x)>c)}{P_{\vartheta_0}(T(x)=c)}, & P_{\vartheta_0}(T(x)=c)>0\\ 0, & P_{\vartheta_0}(T(x)=c)=0\end{cases}$

iii) Niveaugleichung: $E^X_{\vartheta_0}(\varphi_{c,\gamma}) = 1\cdot P_{\vartheta_0}(T(x)>c)+\gamma\cdot P_{\vartheta_0}(T(x)=c)$

$$= \begin{cases} P_{\vartheta_0}(T(X)>c)+\frac{\alpha-P_{\vartheta_0}(T(x)>c)}{P_{\vartheta_0}(T(x)=c)}\cdot P_{\vartheta_0}(T(x)=c)=\alpha, & \gamma\ne0\\ P_{\vartheta_0}(T(X)>c)+0\cdot P_{\vartheta_0}(T(x)=c)=1-P(T(X)\le c)=1-(1-\alpha)=\alpha, & \gamma=0\end{cases}$$

Bsp von oben fortgesetzt: $X_i\sim Bin(1,\vartheta)$

↳ neuer randomisierter Test: $\varphi_{c,\gamma}(X)=\begin{cases}1,&T(x)>c\\ \gamma,&T(x)=c\\0,&T(x)<c\end{cases}$

↳ mit $c:=\inf\{t\in\mathbb R: P_{\vartheta_0}(T(X)\le t)\ge1-\alpha\}$

≙ kleinstes (1-α)-Quantil von $Bin(n,\vartheta_0)$

↳ mit $\gamma:=\frac{\alpha-P_{\vartheta_0}(T(x)>c)}{P_{\vartheta_0}(T(x)=c)}$

↳ Gütefkt: $G_{\varphi_{c,\gamma}}(\vartheta)=P_\vartheta(\sum_{i=1}^n X_i>c)+\gamma\cdot P_\vartheta(\sum_{i=1}^n X_i=c)$

$=\sum_{k=c+1}^n\binom nk\cdot\vartheta^k\cdot(1-\vartheta)^{n-k}+\gamma\cdot\binom nc\cdot\vartheta^c\cdot(1-\vartheta)^{n-c}$

Quantilfunktion

- $F:\mathbb R\to[0,1]$ heißt Verteilungsfunktion mit $F(x)=P(X\le x)$, falls
  - i) F monoton wachsend
  - ii) F ist rechtsseitig stetig
  - iii) $\lim_{x\to-\infty}F(x)=0$; $\lim_{x\to\infty}F(x)=1$

Bsp: $Bin(3,\frac12)$ mit $f(x)=P(X=x)=\binom3x\cdot(\frac12)^x\cdot(\frac12)^{3-x}=\binom3x\cdot(\frac12)^3$

=> $F(x)=\begin{cases}0, & x<0\\ \frac18\cdot\sum_{i=0}^{\lfloor x\rfloor}\binom3i, & 0\le x<3\\ 1, & 3\le x\end{cases}$

5.18) Quantilsfunktion $F^{-1}(y)=\inf\{x\in\mathbb R: F(x)\ge y\}$

↳ Eigenschaften i) F^{-1} ist monoton wachsend

↳ Bew: Seien $y_1,y_2\in\mathbb R$, $y_1<y_2$

=> $\{x\in\mathbb R:F(x)\ge y_2\}\subseteq\{x\in\mathbb R:F(x)\ge y_1\}$

=> $\inf\{x\in\mathbb R:F(x)\ge y_1\}\le\inf\{x\in\mathbb R:F(x)\ge y_2\}$

ii) F^{-1} ist linksseitig stetig

iii) $F(x)\ge y \Leftrightarrow x\ge F^{-1}(y)$

↳ Bew: „=>" $x\ge\inf\{\tilde x\in\mathbb R: F(\tilde x)\ge y\}=F^{-1}(y)$

„<=" $F(x)\ge F(F^{-1}(y))=\lim_{\varepsilon\to0}F(F^{-1}(y)+\varepsilon)\ge y$

iv) $F(x-)\le y$ => $x\le F^{-1}(y+)$

v) F ist stetig => $F(F^{-1}(y))=y$

vi) $F\circ F^{-1}\circ F=F$; $F^{-1}\circ F\circ F^{-1}=F^{-1}$

5.20) X hat stetige Verteilungsfunktion F => $F(x)\sim U(0,1)$

5.21) α-Quantil: $P(X\le q_\alpha)\ge\alpha$ und $P(X\ge q_\alpha)\ge1-\alpha$

=> $q_\alpha=F^{-1}(\alpha)=\inf\{x\in\mathbb R:F(x)\ge\alpha\}$

↳ Falls diskrete W'Verteilung, also F Treppenfunktion

=> q_α sind Intervalle: $q_\alpha\in[F^{-1}(\alpha),F^{-1}(\alpha+)]$

↳ Bew: $q_\alpha\in[F^{-1}(\alpha);F^{-1}(\alpha+)] \Leftrightarrow q_\alpha\ge F^{-1}(\alpha)\wedge q_\alpha\le F^{-1}(\alpha+)$

$\Leftrightarrow F(q_\alpha)\ge\alpha \wedge 1-P(X<q_\alpha)\ge1-\alpha$

=> $F^{-1}(\alpha)$ liefert das kleinste α-Quantil

P-Wert $p(x)=P_{\vartheta_0}(T(X)\ge t_0)$ mit $t_0=T(x)$

↳ W'keit, die Beobachtung oder in Richtung von H_1 extremeren Wert zu erhalten unter der Annahme dass die Nullhypothese stimmt

↳ niedrigstes Signifikanzniveau zu dem Ho auf Basis der Beobachtung noch abgelehnt werden würde

=> $p(x)=P_{\lambda_0}(T(X_1,\dots,X_n)\ge T(x))$ ↗ Richtung von H_1 ↳ hängt von Testproblem ab

Optimale Tests

- i.A. widersprechen sich Forderungen:

i) $G_\varphi(\vartheta)$ für $\vartheta\in\Theta_0$ minimieren (Fehler 1. Art)

ii) $G_\varphi(\vartheta)$ für $\vartheta\in\Theta_1$ maximieren (Schärfe bzw. 1-(Fehler 2. Art))

=> Vergrößerung des Annahmebereichs verkleinert Fehler 1. Art, vergrößert aber W'keit für Fehler 2. Art

6.1) i) φ_1 gleichmäßig besser als φ_2, falls $G_{\varphi_1}(\vartheta)\ge G_{\varphi_2}(\vartheta)\ \forall\vartheta\in\Theta_1$

ii) φ^* gleichmäßig bester Test, falls $G_{\varphi^*}(\vartheta)\ge G_\varphi(\vartheta)\ \forall\vartheta\in\Theta_1\ \forall\varphi\in\Phi(\alpha)$

6.2) unverfälschte Tests

φ ist unverfälschter Test zum Niveau α, falls $G_\varphi(\vartheta)\le\alpha\ \forall\vartheta\in\Theta_0$ und $G_\varphi(\vartheta)\ge\alpha\ \forall\vartheta\in\Theta_1$

Beste Tests für einfache Hypothesen

nicht-randomisierter Neymann-Pearson-Test

- Alternativtestproblem $H_0:P^X=P_0^X$; $H_1:P^X=P_1^X$
- für diskrete Verteilungen mit Zähldichten f_0, f_1

↳ $N=\{x\in X: f_0(x)=f_1(x)=0\}$ spielt keine Rolle, da sie keine W'keit trägt

=> gesucht: unter allen Verwerfungsbereichen $S\subseteq X\setminus N$ ($\varphi=1$) mit Bedingung $P_0^X(S)=\sum_{x\in S}f_0(x)\le\alpha$ (Fehler W'keit 1. Art) wird die mit max. Schärfe gesucht: $P_1^X(S)=\sum_{x\in S}f_1(x)\to\max_S$

↳ wird ein $x\in X\setminus N$ zu S hinzugenommen, wird $P_0^X(S)$ um $f_0(x)$ größer (schlecht) und $P_1^X(S)$ um $f_1(x)$ größer (gut)

=> am besten sind die x für die $\frac{f_1(x)}{f_0(x)}$ möglichst groß ist

=> Teststatistik $T(x)=\begin{cases}\frac{f_1(x)}{f_0(x)}, & f_0(x)>0\\ \infty, & f_0(x)=0\end{cases}$ mit $\varphi_c(x)=\begin{cases}1, & T(x)\ge c\\0, & T(x)<c\end{cases}$

↳ Bew: zzg.: $E_1^X(\varphi_c)\ge E_1^X(\varphi)$ für alle Vergleichstests φ

- Def: $M^+:\{x\in X:\varphi_c(x)>\varphi(x)\}$, $M^-:\{x\in X:\varphi_c(x)<\varphi(x)\}$

=> $x\in M^+$ => $\varphi_c(x)>0$ => $f_1(x)\ge c\cdot f_0(x)$

$x\in M^-$ => $\varphi_c(x)<0$ => $f_1(x)\le c\cdot f_0(x)$

=> $\int(\varphi_c-\varphi)(f_1-c\cdot f_0)\,d\mu^X$

$=\int_{M^+}(\varphi_c-\varphi)(f_1-c\cdot f_0)\,d\mu^X+\int_{M^-}(\varphi_c-\varphi)(f_1-c\cdot f_0)\,d\mu^X\ge0$

=> $E_1^X(\varphi_c)-E_1^X(\varphi)=\int\varphi_c\,dP_1^X-\int\varphi\,dP_1^X=\int(\varphi_c-\varphi)\cdot f_1\,d\mu^X$

$\ge\int(\varphi_c-\varphi)\cdot c\cdot f_0\,d\mu^X=c\cdot(\underbrace{E_0^X(\varphi_c)}_{=\alpha}-\underbrace{E_0^X(\varphi)}_{\le\alpha})\ge0$

6.5) Falls $T(x)=\begin{cases}\frac{f_1(x)}{f_0(x)}, & f_0(x)>0\\\infty, & f_0(x)=0\end{cases}$ Sprungstellen hat, kann nicht jedes Niveau $\alpha=1-P_0^X(T(x)<c)$ angenommen werden

6.6) Neymann-Pearson-Test für $H_0:P^X=P_0^X$; $H_1:P^X=P_1^X$

$\varphi_{c,\gamma}(x)=\begin{cases}1,&T(x)>c\\\gamma,&T(x)=c\\0,&T(x)<c\end{cases}$ mit $T(x)=\begin{cases}\frac{f_1(x)}{f_0(x)},&f_0(x)>0\\\infty,&f_0(x)=0\end{cases}$

↳ ist glm. bester Test zum Niveau $\alpha=\int\varphi_{c,\gamma}\,dP_0^X$

↳ Bew: analog zu 6.4)

↳ für vorgegebenes α gibt es $c\ge0$, $\gamma\in[0,1]$ mit $E_0^X(\varphi_{c,\gamma})=P_0(T(X)>c)+\gamma\cdot P_0(T(X)=c)=\alpha$

↳ Bew: Konstruktiv:

$c:=\inf\{t\in\mathbb R: F_0(t)\ge1-\alpha\}$ ≙ (1-α)-Quantil von F_0

$\gamma=\begin{cases}0 & \text{falls } P_0(T(x)=c)=0 \quad \text{stetig}\\ \frac{F_0(c)-(1-\alpha)}{F_0(c)-F_0(c^-)} & \text{falls } P_0(T(x)=c)>0 \quad \text{diskret}\end{cases}$

=> mit dem c und γ Niveaugleichung nachrechnen

↳ Neymann-Pearson-Test ist als glm. bester Test eindeutig

6.9) Für glm. besten Test φ^* zu $H_0:P^X=P_0^X$; $H_1:P^X=P_1^X$ gilt

entweder $E_0^X(\varphi^*)=\int\varphi^*\,dP_0^X=\alpha$ (schöpft Niveau α aus)

oder $E_1^X(\varphi^*)=\int\varphi^*\,dP_1^X=1$ (Schärfe = 1)

↳ Bew: Widerspruch

6.10) Sei φ^* glm. bester Test, dann gilt: $E_1^X(\varphi^*)\ge\alpha$, d.h. φ^* ist unverfälschter Test

↳ Bew: konst. Test $\varphi(x)=\alpha$ ist wegen $E_0^X(\varphi)=\alpha$ ein α-Niveau-Test mit $E_1^X(\varphi)=\alpha$

=> ist φ^* glm. bester Test, muss also gelten $E_1^X(\varphi)\ge\alpha$

Beste Tests für zusammengesetzte Hypothesen

Bsp: Optimalität einseitiger Gauß-Test: $X_i\sim N(\mu,\sigma_0^2)$

↳ stat. Modell: $(\mathbb R^n,\mathcal B^n,\{\bigotimes_{i=1}^n N(\mu,\sigma_0^2):\mu\in\mathbb R\})$

↳ Testproblem: $H_0:\mu\le\mu_0$; $H_1:\mu>\mu_0$

↳ Test: $\varphi^*(x)=\begin{cases}1, & \tilde T(x)=\frac{\bar x_n-\mu_0}{\sigma_0/\sqrt n}>c\\0,&\text{sonst}\end{cases}$ mit c ≙ (1-α)-Quantil der N(0,1)-Verteilung

=> Ist bester Test für das Testproblem zum Niveau $\alpha=E^X_{\mu_0}(\varphi^*)$

↳ Bew: 1. Schritt: Alternativtestproblem: $H_0':\mu=\mu_0$; $H_1':\mu=\mu_1$; $\mu_1>\mu_0$

- nach 6.7) gibt es glm. besten Test

- Dichtequotient: $T(x)=\frac{f(x,\mu_1)}{f(x,\mu_0)}=\frac{e^{-\frac12(\frac{x_i-\mu_1}{\sigma_0})^2}}{e^{-\frac12(\frac{x_i-\mu_0}{\sigma_0})^2}}=\dots=e^{\frac{\mu_1-\mu_0}{\sigma_0/\sqrt n}\cdot\tilde T(x)+\text{konst}}$

↳ T(x) streng mon. wachsend in $\tilde T(x)$

=> $\tilde c=\frac{\sigma_0/\sqrt n}{\mu_1-\mu_0}$ => damit sind Verw.- & Rand.-bereich von T & $\tilde T$ gleich

↳ das $\tilde c$ und γ bestimmen: $P_{\mu_0}(T(x)>\tilde c)+\gamma\cdot P_{\mu_0}(T(x)=\tilde c)=\alpha$

2. Schritt: $H_0:\mu=\mu_0$; $H_1:\mu>\mu_0$ folgt aus Schritt 1, denn μ_1 beliebig

3. Schritt: $H_0:\mu\le\mu_0$; $H_1:\mu>\mu_0$

$G_{\varphi^*}(\mu)=1-\Phi(\tilde c-\frac{\mu-\mu_0}{\sigma_0/\sqrt n})$ ist mon. wachs. in μ => $E^X_{\mu_0}(\varphi)\le E^X_{\mu_0}(\varphi^*)=\alpha$

=> also ist beliebiger Vergleichstest φ schlechter

↳ falls $H_0:\mu\ge\mu_0$; $H_1:\mu<\mu_0$: bei φ^* "<" statt ">"

=> analog ist der einseitige Binomialtest glm. bester Test

Bsp: Optimalität zweiseitiger Gauß-Test: $X_i\sim N(\mu,\sigma_0^2)$

↳ stat. Modell: $(\mathbb R^n,\mathcal B^n,\{\bigotimes_{i=1}^n N(\mu,\sigma_0^2):\mu\in\mathbb R\})$

↳ Testproblem: $H_0:\mu=\mu_0$; $H_1:\mu\ne\mu_0$

↳ Test: $\varphi^*(x)=\begin{cases}1,&|T(x)|=\left|\frac{\bar x_n-\mu_0}{\sigma_0/\sqrt n}\right|>c\\0,&\text{sonst}\end{cases}$ mit c ≙ (1-α/2)-Quantil der N(0,1)-Verteilung

=> geht nicht, denn es müsste glm. bester α-Niveau-Test sein für $H_0:\mu=\mu_0$; $H_1^>:\mu>\mu_0$ und $H_0:\mu=\mu_0$; $H_1^<:\mu<\mu_0$

↳ Wegen Monotonie von einseitigem Gauß-Test erhält man Widerspruch

=> Wenn man die Klasse der Tests einschränkt auf unverfälschte Tests dann ist zweiseitiger Gauß Test glm. bester unverfälschter α-Niveau-Test

6.14) Analog gilt gleiches für ein- & zweiseitigen t-Test falls σ^2 unbekannt

Zwei unabhängige Stichproben:

- $X_1,\dots X_{n_1}\overset{iid}{\sim}N(\mu_1,\sigma_1^2)$; $Y_1,\dots,Y_{n_2}\overset{iid}{\sim}N(\mu_2,\sigma_2^2)$
- Testproblem: $H_0:\mu_1\overset{\ge}{\le}\mu_2$ gegen $H_1:\mu_1\overset{<}{>}\mu_2$
- $\sigma_1^2=\sigma_2^2$ sind unbekannt

$T(X,Y)=\frac{\bar X_{n_1}-\bar Y_{n_2}}{S_p\cdot\sqrt{\frac1{n_1}+\frac1{n_2}}}\overset{\mu_1=\mu_2}{\sim}t_{(n_1+n_2-2)}$

Achtung ↗

mit $S_p^2=\frac{n_1-1}{n_1+n_2-2}S_{n_1}^2+\frac{n_2-1}{n_1+n_2-2}S_{n_2}^2$

=> $\varphi^*(x,y)=\begin{cases}1,&T(x_1,\dots,x_n,y_1,\dots,y_n)>t_{n_1+n_2-2,1-\alpha}\\0,&\text{sonst}\end{cases}$ $<t_{n_1+n_2-2,\alpha}$

=> ist glm. bester unverfälschter α-Niveau-Test

Spezielle Testprobleme

Kolmogorov-Smirnov-Test für $X_1,\dots,X_n\overset{iid}{\sim}F$ stetig

- stat. Modell: $(\mathbb R^n,\mathcal B^n,P^X=\{\bigotimes_{i=1}^n P^{X_i}: P^{X_i}\text{ hat stetige VF }F\})$
- Testproblem: $H_0:F=F_0$; $H_1:F\ne F_0$
- Teststatistik für eine Beobachtung $(x_1,\dots,x_n)\in\mathbb R^n$

Empirische VF: $F_n(z,x_1,\dots,x_n)=\frac1n\cdot\sum_{i=1}^n \mathbb{1}_{(-\infty,z]}(x_i)$

$=\frac1n\cdot$(Anz der x_i mit $x_i\le z$)

=> Teststatistik: $D_n(X_1,\dots,X_n)=\sup_{z\in\mathbb R}|F_n(z,X_1,\dots,X_n)-F_0(z)|$

↳ max. Abstand zw. empirischer und theoretischer VF

=> $P_{F_0}(\lim_{n\to\infty}\sup_{z\in\mathbb R}|F_n(z,X_1,\dots,X_n)-F_0(z)|=0)=1$

↳ $D_n(X_1,\dots,X_n)\xrightarrow{n\to\infty}0$ P_{F_0}-f.s.

=> Für Verteilung von D_n unter $H_0:F=F_0$:

7.1) Satz von Kolmogorov

i) Für $H_0:F=F_0$ sind die Verteilungen von F_0 und D_n gleich

ii) Es gilt: $\lim_{n\to\infty}P_{F_0}(\sqrt n\cdot D_n(X_1,\dots,X_n)\le y)=\tilde K(y)$

mit Kolmogorov VF $\tilde K(y)=\begin{cases}1-2\cdot\sum_{i=1}^\infty(-1)^{i-1}\cdot e^{-2i^2y^2}, & y>0\\0, & y\le0\end{cases}$

↳ Bew: i) Definiere $U_i:=F_0(X_i)\overset{5.20}{\Rightarrow}U_1,\dots,U_n\overset{iid}{\sim}U(0,1)$

=> $P_{F_0}(X_i\le z)=P_{F_0}(F(X_i)\le F_0(z))=P_{F_0}(F_0^{-1}(F_0(X_i))\le z)$

$=P_{F_0}(F_0^{-1}(U_i)\le z)$

$\overset{H_0:F=F_0}{\Rightarrow}F_n(z,X_1,\dots,X_n)=\frac1n\cdot\sum_{i=1}^n \mathbb{1}_{(-\infty,z]}(X_i)=\frac1n\sum_{i=1}^n \mathbb{1}_{(-\infty,z]}(F_0^{-1}(U_i))$

$=\frac1n\cdot\sum_{i=1}^n \mathbb{1}_{(-\infty,F_0(z)]}(U_i)=F_n(F_0(z),U_1,\dots,U_n)$

=> $D_n(X_1,\dots,X_n)=\sup_{z\in\mathbb R}|F_n(z;X_1,\dots,X_n)-F_0(z)|$

$=\sup_{z\in\mathbb R}|F_n(F_0(z),U_1,\dots,U_n)-F_0(z)|$

$=\sup_{t\in(0,1)}|F_n(t,U_1,\dots,U_n)-t|$

$=\sup_{t\in(0,1)}|F_n(t,U_1,\dots,U_n)-F_{U(0,1)}(t)|$

↳ D_n hängt nicht von F_0 ab

Kolmogorov-Smirnoff-Test: $H_0:F=F_0$; $H_1:F\ne F_0$

i) Exakter KS-Test: $\varphi(x)=\begin{cases}1,&D_n(x_1,\dots,x_n)>k_{n,1-\alpha}\\0\end{cases}$

↳ $k_{n,1-\alpha}$ ist (1-α)-Quantil der Verteilung von D_n unter H_0

ii) approximativer Test: $\varphi(x)=\begin{cases}1,&D_n(x_1,\dots,x_n)>\frac{\tilde k_{1-\alpha}}{\sqrt n}\\0\end{cases}$

mit $\tilde k_{1-\alpha}$: (1-α)-Quantil der Verteilung von $\tilde K$ unter H_0 (7.1ii)

↳ Unter H_0:

$P_{F_0}(D_n(X_1,\dots,X_n)>\frac{\tilde k_{1-\alpha}}{\sqrt n})=P_{F_0}(\sqrt n\,D(X_1,\dots,X_n)>\tilde k_{1-\alpha})$

$=1-P_{F_0}(\sqrt n\,D(X_1,\dots,X_n)\le\tilde k_{1-\alpha})\underset{\text{für n groß}}{\approx}1-\tilde K(\tilde k_{1-\alpha})=1-(1-\alpha)=\alpha$

7.2) Beobachtung $(x_1,\dots,x_n)\in\mathbb R^n$ => F_n stetig

=> $D_n(x_1,\dots,x_n)=\sup_{z\in\mathbb R}|F_n(z;x_1,\dots,x_n)-F_0(z)|$ nimmt Supremum an

↳ Durchführung: $D_n(x_1,\dots,x_n)=\max\{|F_n(x_i)-F_0(x_i)|;|F_n(x_i-)-F_0(x_i)|\}$

↳ am oberen und unteren Ende der Treppen immer der Abstand zu $F_0(x)$

Bsp: Prüfung auf Gleichverteilung mit $F_0(x)=x$ $\forall x\in[0,1]$

↳ Testproblem: $H_0:F=F_0(x)$; $H_1:F\ne F_0(x)$

x_i	0,12	0,23	0,64	0,89	0,96
$F_5(x_i)$	0,2	0,4	0,6	0,8	1
$F_5(x_i-)$	0	0,2	0,4	0,6	0,8
$F_0(x_i)$	0,12	0,23	0,64	0,89	0,96
$d_+(x_i)$	0,08	0,17	0,04	0,09	0,04
$d_-(x_i)$	0,12	0,03	0,24	0,29	0,16

approximativer Test:

$D_5(X_i)=0{,}29$

=> $\sqrt5\cdot D_5(X_i)=0{,}648$

$\tilde K_{0,95}=1{,}36$ (Internet)

=> $0{,}648<1{,}36$

=> Entscheidung für Ho

χ^2-Anpassungstest für Multinomialverteilung

- von Stichprobe Häufigkeiten der Ergebnisse prüfen und schauen ob diese nah genug an erwarteter rel. Häufigkeit liegen

7.5) $\vartheta=(\vartheta_1,\dots,\vartheta_s)^T\in(0,1)^s$ mit $\sum_{j=1}^s\vartheta_j=1$: Schätzer für W'keiten

$X=(X_1,\dots,X_s)^T:\Omega\to\mathbb R^s$ ist s-dimensionaler ZV mit $P(X=(1,0,\dots,0)^T)=\vartheta_1$, …, $P(X=(0,0,\dots,1)^T)=\vartheta_1$

=> X heißt multinomialverteilt

7.6) $X\sim M(1,\vartheta)$, dann gilt:

i) $E_p(X)=(E_p(X_1),\dots,E_p(X_s))^T=(\vartheta_1,\dots,\vartheta_s)^T=\vartheta$

ii) $V_p(X)=\begin{pmatrix}\vartheta_1&&0\\&\ddots&\\0&&\vartheta_s\end{pmatrix}-\vartheta\cdot\vartheta^T=\Delta_\vartheta-\vartheta\cdot\vartheta^T$

↳ Denn: $(V_p(X))_{i,j}=\begin{cases}Cov(X_i,X_j), & i\ne j\\Var(X_i), & i=j\end{cases}$

mit: $Var(X_i)=E(\underset{X_i\in\{0,1\}}{X_i^2})-(E(X_i))^2=E(X_i)-\vartheta_i^2=\vartheta_i-\vartheta_i^2$

$Cov(X_i,X_j)=E((X_i-\vartheta_i)(X_j-\vartheta_j))=\dots=-\vartheta_i\vartheta_j$ ↗ $E(X_i\cdot X_j)=0$

Bsp: Modellbildung: $X_1,\dots,X_n\overset{iid}{\sim}M(1,\vartheta)$ mit $\vartheta\in(0,1)^s$ und $\sum_{j=1}^s\vartheta_j=1$

$E=\{1,\dots,s\}$ sei Menge möglicher Ergebnisse

↳ stat. Modell: $(E^n,P(E^n),\{\bigotimes_{i=1}^n M(1,\vartheta):\vartheta\in(0,1)^s\text{ mit }\sum_{j=1}^s\vartheta_j=1\})$

↳ Testproblem: $H_0:\vartheta=\vartheta_0$; $H_1:\vartheta\ne\vartheta_0$ für $\vartheta_0=(0,1)^s$ mit $\sum_{j=1}^s(\vartheta_0)_j=1$

↳ Teststatistik: von allen Stichproben die i-te Komponente (0 oder 1) aufsummiert

$T(X_1,\dots,X_n)=T(\begin{pmatrix}X_{11}\\\vdots\\X_{1s}\end{pmatrix},\dots,\begin{pmatrix}X_{n1}\\\vdots\\X_{ns}\end{pmatrix})=\sum_{j=1}^s\frac{(\sum_{i=1}^n x_{ij}-n(\vartheta_0)_j)^2}{n\cdot(\vartheta_0)_j}\overset{as.}{\underset{H_0}{\sim}}\chi^2_{s-1}$

↳ Test: $\varphi(X_1,\dots,X_n)=\begin{cases}1,&T(X_1,\dots,X_n)>c\\0,&T(X_1,\dots,X_n)\le c\end{cases}$ mit c ≙ (1-α)-Quantil von χ^2_{s-1}

7.7) Da die Teststatistik nur asymptotisch χ^2_{s-1} verteilt ist gibt es die Faustregel, dass n mindestens so groß sein muss, dass $n\cdot\vartheta_j^0\ge5$, $1\le j\le s$

Bsp: n-maliges Werfen eines Würfels $X_1,\dots,X_n\overset{iid}{\sim}M(1,\vartheta)$; $\begin{pmatrix}\vartheta_1\\\vdots\\\vartheta_6\end{pmatrix}\in(0,1)^6$

- Stichprobe n=30:

j	1	2	3	4	5	6
$\sum_{i=1}^{30}x_{ij}$	7	2	5	8	5	3

- Voraussetzung: $n\cdot\vartheta_j^0=30\cdot\frac16\ge5$ $\forall j$
- Teststatistik: $T(X_1,\dots,X_n)=\frac15\cdot\sum_{j=1}^6(\sum_{i=1}^{30}x_{ij}-5)^2=\frac{4+9+9+4}{5}=5{,}2$
- $\alpha=5\%$, $c=\chi^2_{5;0,95}\approx11{,}07$

=> $T(x_1,\dots,x_n)<c$

=> mit H_0 verträglich

- p-Wert: $p(x_1,\dots,x_{30})=P_{\vartheta_0}(T(X_1,\dots,X_{30})\ge5{,}2)$

$=1-F_{\chi^2_5}(5{,}2)$

$=1-\text{pchisq}(5.2,5)$

$=39{,}2\,\%$

χ^2-Anpassungstest

=> auch für stetige Verteilung

↳ Idee: • Wertebereich von X_1 in s disjunkte Intervalle zerlegen: $I_1,\dots,I_s$

• Def: $\vartheta_j:=P_F(X_1\in I_j)$ bzw $(\vartheta_0)_j:=P_{F_0}(X_1\in I_j)$

=> $\vartheta_j\in(0,1)$ und $\sum_{j=1}^s\vartheta_j=1$

- $X_1,\dots,X_n\overset{iid}{\sim}F$; F_0 beliebige VF; $\alpha\in(0,1)$
- Testproblem: $H_0:F=F_0$; $H_1:F\ne F_0$
- reduziertes Testproblem: $H_0:\vartheta=\vartheta_0$; $H_1:\vartheta\ne\vartheta_0$ mit $\vartheta=\begin{pmatrix}\vartheta_1\\\vdots\\\vartheta_s\end{pmatrix}$, $\vartheta_0=\begin{pmatrix}(\vartheta_0)_1\\\vdots\\(\vartheta_0)_s\end{pmatrix}$
- Teststatistik: Def: $Y_j=|\{X_i: x_i\in I_j\}|$

=> $T(Y_1,\dots,Y_n)=\sum_{j=1}^s\frac{(Y_j-n\cdot(\vartheta_0)_j)^2}{n\cdot(\vartheta_0)_j}$

- approx. χ^2-Anpassungstest: $\varphi(Y_1,\dots,Y_n)=\begin{cases}1,&T(Y_i)>c\\0,&\text{sonst}\end{cases}$

=> für c: siehe oben bei anderem χ^2-Test

=> Prüft nur ob P_F & P_{F_0} auf $I_1,\dots,I_s$ übereinstimmen

Beispiele:

$E(X|X+Y)$: i) $P(X=k\mid X+Y=n)=\frac{P(\{X=k,Y=n-k\})}{P(X+Y=n)}$

ii) $E(X|X+Y=n)=\int x\cdot P(X=k|X+Y=n)$

iii) Für $E(X|X+Y)$: n durch X+Y ersetzen

$$P(X=x)=\begin{cases}\int_{\mathbb R}P(X=x\mid Y=y)\,dP^Y(y) & ;Y\text{ stetig}\\ \sum_{y\in\mathbb R}P(X=x|Y=y)\cdot P(Y=y) & ;Y\text{ diskret}\end{cases}$$

Faltung: $f_{X+Y}(t)=\int_{\mathbb R}f_X(s)\cdot f_Y(t-s)\,ds$

$Var(X+Y)=Var(X)+Var(Y)+2\cdot Cov(X,Y)$

asympt. Verteilung: 2.22): $\vartheta\overset{asy.}{\sim}N(E(\hat\vartheta);(I_X(\vartheta))^{-1})$

$Cov(\begin{pmatrix}X_1\\X_2\end{pmatrix},X_3)=\begin{pmatrix}Cov(X_1,X_3)\\Cov(X_2,X_3)\end{pmatrix}$

$Var(X+Y)=Var(X)+Var(Y)+2\cdot Cov(X,Y)$

$E(X\cdot Y)=E(X)\cdot E(Y)+Cov(X,Y)$

↳ Denn $Cov(X,Y)=E(X\cdot Y)-E(X)\cdot E(Y)$

ML-Schätzer:

- 2. Ableitung bestimmen, ob Maximum
- zeigen dass ML-Schätzer nicht existiert:

↳ ist f_x dann vlt streng monoton

Wichtige Dichten

$\binom nk=\frac{n!}{k!\cdot(n-k)!}$

Verteilung	E(X)	Var(X)	Dichte	$L_x(\vartheta)$	$\hat\vartheta_{ML}$
Bin(n,p)	$n\cdot p$	$n\cdot p\cdot(1-p)$	$\binom nk\cdot p^k\cdot(1-p)^{n-k}$	$\vartheta^x\cdot(1-\vartheta)^{n-x}$	$\frac xn$
Poi(λ)	λ	λ	$e^{-\lambda}\cdot\frac{\lambda^k}{k!}$	$e^{-\lambda}\cdot\lambda^k$	
Hyp(n,N,M)	$n\cdot\frac MN$	$n\cdot\frac MN\cdot(1-\frac MN)\cdot\frac{N-n}{N-1}$	$\frac{\binom Mk\binom{N-M}{n-k}}{\binom Nn}$		
N(μ,σ²)	μ	σ^2	$\frac1{\sqrt{2\pi}\sigma}\cdot e^{-\frac12\frac{(x-\mu)^2}{\sigma^2}}$		$\frac1n\sum_{i=1}^n x_i$
χ^2_n	n	$2n$	$\frac{\sqrt{1/2}}{\Gamma(\frac12)}\cdot x^{-\frac12}\cdot e^{-\frac12x}$		
Exp(λ)	$\frac1\lambda$	$\frac1{\lambda^2}$	$\lambda\cdot e^{-\lambda x}\cdot\mathbb{1}_{[0,\infty)}(x)$	$F(x)=(1-e^{-\lambda x})\mathbb{1}_{(0,\infty)}$	
U(a,b)	$\frac{b+a}2$	$\frac1{12}\cdot(b-a)^2$	$\frac1{b-a}\cdot\mathbb{1}_{[a,b]}$	$\frac{\mathbb{1}_{[\max(x_i),\infty)}(\vartheta)}{\vartheta^n}$	$\max(x_i)$
t_n					

Transformationsformel

$T:(\Omega,\mathcal A)\to(\Omega',\mathcal A')$; $\Omega,\Omega'\subseteq\mathbb R^k$; $\mathcal A=\mathcal B^k_{|\Omega}$; $\mathcal A'=\mathcal B^k_{|\Omega'}$

μ hat λ^k-Dichte f ($\mu\ll\lambda^k$); T bijektiv; T^{-1} diff-bar

=> μ^T hat λ^k-Dichte h: $h=f\circ T^{-1}\cdot|\det DT^{-1}|$

↳ Bsp: $X\sim Exp(6)=P^X$

Gesucht: λ-Dichte von P^Y mit $Y=3X+\ln(6)$

=> $Exp(6)\ll\lambda$ mit Dichte $6\cdot e^{-6x}\cdot\mathbb{1}_{[0,\infty)}(x)$

Definiere $T(x)=3x+\ln(6)$ => $T^{-1}=\frac13\cdot(x-\ln(6))$

=> $\frac{d}{dx}T^{-1}(x)=\frac13$

=> $h(x)=f(T^{-1}(x))\cdot\frac13=6\cdot e^{-6(\frac13(x-\ln6))}\cdot\mathbb{1}_{[0,\infty)}(\frac13(x-\ln6))\cdot\frac13$

$=\dots=72\cdot e^{-2x}\cdot\mathbb{1}_{[\ln6;\infty)}(x)$

R-Befehle

- $\Phi(-\sqrt n)\le0{,}01$ => $-\sqrt n\le\Phi^{-1}(0{,}01)$ = qNorm(0,01)
- pNorm(1) ≙ $\Phi(1)$ ≙ F(1)
- Dichte: dNorm(1) ≙ f(1)
- rNorm(80, m=5, sd=1) gibt 80 N(5,1) verteilte Zufallszahlen aus
- qBinom(x, size, prob) analog
- rUnif(100, a=0, b=2) => 100x U(0,2)
- qt(0,99, 5) ≙ 99% - Quantil von t_5

Interpretation p-Wert:

„niedrigstes Niveau α, zu dem H_0 auf Basis der Beobachtung noch abgelehnt werden müsste"

„da p-Wert recht hoch, ist er mit H_0 verträglich"

statistisches Modell bei 2 Stichproben Test:

$(\mathbb R^n\times\mathbb R^m,\mathcal B^n\otimes\mathcal B^m,\{\bigotimes_{i=1}^n N(\mu_1,\sigma^2)\otimes\bigotimes_{j=1}^m N(\mu_2,\sigma^2):\mu_1,\mu_2\in\mathbb R;\sigma^2>0\})$

Charakter. Fkt:

↳ 1. Dim: $X\sim N(0,1)$ => $\varphi_X=e^{-\frac12t^2}$

↳ n. dim: $X\sim N_n(0,1)$ => $\varphi_X=e^{-\frac12t\cdot t^T}$

Wichtige Integrale

$\int\frac{x}{x-1}dx=x+\ln(|x-1|)$